

VERİ MADENCİLİĞİ RAPOR

Dry Bean Dataset


Farklı kuru fasulye türlerinin sadece fiziksel ve geometrik özelliklerine bakarak makine öğrenmesi ile otomatik sınıflandırılması.

Pınar Nida Tunca

8/6/2026

Github Repo: [Dry-Bean-Classification](#)

Youtube Link: [Dry-Bean-Sunum](#)



İÇİNDEKİLER

1. GİRİŞ VE LİTERATÜR TARAMASI

- 1.1. Problem Tanımı ve Projenin Amacı
- 1.2. Veri Setinin Tanıtımı
- 1.3. Referans Akademik Çalışmanın İncelenmesi ve Temel Alınan Makale Sonuçları

2. KEŞİFSEL VERİ ANALİZİ (EDA)

- 2.1. Hedef Değişken Analizi ve Sınıf Dengesizliği Grafiği
- 2.2. Geometrik ve Şekilsel Değişkenlerin İstatistiksel Dağılımları

3. VERİ ÖN İŞLEME (Data Preprocessing)

- 3.1. Eksik Veri Kontrolü ve Uygun Doldurma Stratejileri
- 3.2. Bilgi Değeri Düşük veya Gereksiz Sütunların Ayıklanması
- 3.3. Aykırı Değer (Outlier) Tespiti: Kutu Grafikleri (Boxplots) ve IQR Yöntemi ile Temizleme

4. ÖZELLİK MÜHENDİSLİĞİ (Feature Engineering)

- 4.1. Mevcut Sütunlardan Anlamlı ve Yeni Geometrik Özelliklerin Türetilmesi
- 4.2. Özellikler Arası İlişkiler: Korelasyon Analizi ve Isı Haritası (Heatmap)
- 4.3. Özellik Ölçeklendirme ve Standardizasyon (SVM Modeli İçin Verinin Hazırlanması)

5. MODELLEME SÜRECİ (Modeling)

- 5.1. Veri Setinin Bağımsız Özellikler (X) ve Bağımlı Sınıf (y) Olarak Ayrılması
- 5.2. Veri Bölümleme Stratejisi: Eğitim (Train) ve Test Setleri
- 5.3. Doğrulama (Validation) Stratejisi: K-Fold Çapraz Doğrulama Entegrasyonu
- 5.4. Destek Vektör Makineleri (SVM) Model Mimarisi ve Hiperparametre Seçimi (Kernel Seçimi)

6. PERFORMANS DEĞERLENDİRMESİ VE AKADEMİK KARŞILAŞTIRMA

- 6.1. Sınıflandırma Sonuçları Karmaşıklık Matrisi (Confusion Matrix) Görselleştirilmesi
- 6.2. Yaygın Değerlendirme Ölçütlerinin Analizi (Accuracy, Sensitivity, Precision, F-Measure)
- 6.3. Elde Edilen Deneysel Sonuçların Referans Akademik Makale ile Kıyaslanması

7. SONUÇ VE DEĞERLENDİRME

- 7.1. Proje Kazanımları ve Bulguların Özeti

KAYNAKÇA

1. GİRİŞ VE LİTERATÜR TARAMASI

1.1. Problem Tanımı ve Projenin Amacı

Tarım ve gıda endüstrisinde, ürünlerin kalitesini belirlemek ve piyasa standartlarını sağlamak için tohumların doğru sınıflandırılması kritik bir süreçtir. Geleneksel yöntemlerde kuru fasulye gibi tarım ürünlerinin türlerine göre ayrılması insan gücüne ve gözlemine dayanmaktadır. Bu durum hem zaman alıcı hem de maliyetlidir; ayrıca insan faktöründen kaynaklanan hata payı yüksektir. Bu projenin temel amacı, makine öğrenmesi tekniklerini (özellikle Destek Vektör Makineleri - SVM) kullanarak, kuru fasulyelerin sadece fiziksel ve geometrik ölçümlerine bakarak hangi türe ait olduklarını otomatik, hızlı ve yüksek doğrulukla tahmin edebilen bir yapay zeka modeli geliştirmektir.

1.2. Veri Setinin Tanıtımı

Bu projede kullanılan "Dry Bean Dataset", 7 farklı tescilli kuru fasulye türüne (Dermason, Sira, Sekerci, Horoz, Cali, Barbunya, Bombay) ait verileri içermektedir. Veri seti toplam 13.611 adet fasulye tanesinden oluşmaktadır. Yüksek çözünürlüklü kameralarla çekilen fotoğraflar üzerinden bilgisayarlı görü (computer vision) teknikleri kullanılarak her bir fasulye için 16 adet sayısal özellik (Alan, Çevre, Dışmerkezlilik, Dışbükey Alan vb.) çıkarılmıştır. Veri setinin hedef değişkeni (Class), bu 7 türden birini temsil eden kategorik bir etikettir.

1.3. Referans Akademik Çalışmanın İncelenmesi ve Temel Alınan Makale Sonuçları


Bu veri seti literatüre ilk olarak Koklu ve Ozkan (2020) tarafından *"Multiclass classification of dry beans using computer vision and machine learning techniques"* adlı çalışma ile kazandırılmıştır. İlgili makalede yazarlar, fasulyeleri sınıflandırmak için MLP, SVM, KNN ve Karar Ağaçları gibi algoritmaları kıyaslamışlardır. Yazarların elde ettiği bulgulara göre, en yüksek sınıflandırma başarısını **%93.13 ile SVM, %92.52 ile kNN ve %91.73 ile MLP** modelleri göstermiştir. Bu projede de temel algoritma olarak SVM kullanılacak olup, elde edilen sonuçlar (Accuracy, Sensitivity, F-measure) Koklu ve Ozkan'ın referans değerleri (%93.13) ile doğrudan karşılaştırılarak modelin başarısı ölçülecektir.

(Referans: Koklu, M., & Ozkan, I. A. (2020). *Multiclass classification of dry beans using computer vision and machine learning techniques. Computers and Electronics in Agriculture, 174, 105507.*)

2. KEŞİFSEL VERİ ANALİZİ (EDA)

2.1. Hedef Değişken Analizi ve Sınıf Dengesizliği Grafiği

Hedef değişkenimiz olan "Class" (Fasulye Türü) sütunu üzerinde yapılan frekans analizi ve görselleştirme (Şekil 2.1) sonucunda, sınıflar arasında belirgin bir dengesizlik (imbalance) olduğu tespit edilmiştir.



Şekil 2. 1: Sınıf Frekansları


Elde edilen sayılara göre:

- En yüksek frekansa sahip tür **Dermason (3.546 adet)** iken,
- En düşük frekansa sahip tür **Bombay'dır (522 adet)**.

Sınıflar arasındaki bu sayısal uçurum, modelin eğitim aşamasında Dermason türünü çok daha iyi öğrenirken, Bombay türünü tanımakta zorlanabileceğini (bias) göstermektedir. Bu sebeple modelin performansını değerlendirirken yalnızca Doğruluk (Accuracy) metriğine güvenmek yanıltıcı olabilir. Bu projede, azınlık sınıflarının (Bombay vb.) doğru tahmin edilip edilmediğini adil bir şekilde ölçebilmek için Sensitivity (Duyarlılık) ve özellikle F-Measure metrikleri temel alınmıştır. Ek olarak, modelleme aşamasında sınıf dengesizliğinin algoritmayı yanıltmasını (bias) önlemek amacıyla SVM'in `class_weight='balanced'` hiperparametresi devreye sokularak bu sayısal uçurumun model üzerindeki olumsuz etkisi matematiksel olarak giderilmiştir.

2.2. Geometrik ve Şekilsel Değişkenlerin İstatistiksel Dağılımları

Veri setindeki fasulye türlerinin fiziksel karakteristiklerini ve birbirlerinden nasıl ayrıştıklarını gözlemlemek amacıyla en temel dört geometrik özellik (Alan - Area, Çevre - Perimeter, Majör Eksen Uzunluğu - MajorAxisLength, Minör Eksen Uzunluğu - MinorAxisLength) kutu grafikleri (boxplot) kullanılarak görselleştirilmiştir (Şekil 2.2 ve Şekil 2.3).



Şekil 2.2: Boxplot Görüntüleri

Grafikler incelendiğinde elde edilen temel bulgular şunlardır:

- **Fiziksel Ayrışma :** "Bombay" türü, hem alan hem de çevre uzunluğu bakımından diğer 6 türden çok keskin bir şekilde ayrılmaktadır. Kutu grafiklerinin y-eksenindeki konumu, Bombay türünün veri setindeki en iri fasulye çeşidi olduğunu kanıtlamaktadır.
- "Dermason" ve "Seker" türleri ise fiziksel boyut olarak en küçük sınıfları oluşturmaktadır.
- "Barbunya", "Cali" ve "HoroZ" türlerinin boyut ölçümlerinde birbirlerine daha yakın değerler aldığı (kutü boylarının çakıştığı) gözlemlenmiştir. Bu durum, modelin Bombay türünü çok kolay tahmin edebileceğini, ancak birbirine benzeyen bu orta boylu türleri ayırırken zorlanabileceğini işaret etmektedir.

3. VERİ ÖN İŞLEME (DATA PREPROCESSING)

3.1. Eksik Veri Kontrolü ve Uygun Doldurma Stratejileri

Makine öğrenmesi modelleri (özellikle SVM), eksik verilerle (NaN/Null) karşılaştığında hesaplama yapamayarak hata verir. Bu nedenle modelleme öncesinde veri setinin eksiklik analizi yapılmıştır. Python'un Pandas kütüphanesi kullanılarak (`df.isnull().sum()`) yapılan tarama sonucunda, 13.611 satır ve 17 sütundan oluşan veri setinin hiçbir hücrelerinde eksik değere rastlanmamıştır. Veri seti %100 doluluk oranına sahip olduğu için ortalama (mean), medyan (median) veya KNN Imputer gibi herhangi bir eksik veri doldurma stratejisi uygulanmasına gerek duyulmamıştır.

3.2 Bilgi Değeri Düşük veya Gereksiz Sütunların Ayıklanması

Veri setinde bulunan 16 bağımsız değişkenin (X) tamamı, yüksek çözünürlüklü fotoğraflardan bilgisayarlı görü algoritmaları ile çıkarılmış fiziksel ve geometrik ölçümlerdir (Alan, Çevre, Dışmerkezlilik vb.). Veri setinde modelin kafasını karıştırabilecek veya hiçbir analitik değer taşımayan (örneğin; ID numarası, isim, tarih veya tek bir sabit değerden oluşan sıfır varyanslı sütunlar) herhangi bir gereksiz değişken bulunmamaktadır. Bu nedenle veri ön işleme aşamasında hiçbir sütun silinmemiş, değişkenlerin tamamı korunmuştur. (Not: Değişkenler arası yüksek korelasyon durumu Bölüm 4'te ele alınacaktır).

3.3 Aykırı Değer (Outlier) Tespiti: Kutu Grafikleri (Boxplots) ve IQR Yöntemi ile Temizleme

Geliştirilen tür bazlı IQR algoritması sonucunda, toplam 13.611 örnekten istatistiksel olarak aykırı değer (outlier) barındıran 1.968 adet örnek tespit edilerek veri setinden çıkarılmıştır. Kalan 11.643 adet temizlenmiş örnek ile veri seti, makine öğrenmesi modeline hazır hale getirilmiştir. Veri setinden %14.4 oranında veri silinmesi ilk bakışta yüksek bir oran gibi görünse de, bu işlem sınıflar arası örtüşmeye (overlap) sebep olan ve modelin matematiksel karar sınırlarını (decision boundaries) bozan gürültülü verilerin arındırılması açısından kritik bir adımdır. Uygulanan bu katı veri temizliği stratejisi, makine öğrenmesi algoritmalarının referans çalışmalara kıyasla daha genellenebilir ve kararlı çalışabilmesi için bilinçli olarak tercih edilmiştir.

4. ÖZELLİK MÜHENDİSLİĞİ (FEATURE ENGINEERING)

4.1. Mevcut Sütunlardan Anlamlı ve Yeni Geometrik Özelliklerin Türetilmesi

Makine öğrenmesi modelinin (SVM) fasulye türlerini birbirinden daha kesin çizgilerle ayırabilmesi için, temel 2 boyutlu ölçümleri (Alan, Çevre, Eksenler) kullanarak fiziksel anlam taşıyan 2 yeni özellik (feature) türetilmiştir:

- Şekil Karmaşıklığı (Shape Complexity): Bir nesnenin çevresinin karesinin alanına oranıdır. Bu metrik, fasulyenin dairesel mi yoksa uzun/düzensiz bir yapıya mı sahip olduğunu tek bir sayı ile modele aktarmaktadır.


$$(Shape_Complexity = \frac{Perimeter^2}{Area})$$

- Söзде Hacim (Pseudo Volume): Veri setinde fasulyelerin yalnızca 2 boyutlu fotoğrafik ölçümleri bulunmaktadır. Ancak fasulyeler doğaları gereği 3 boyutlu elipsoid nesnelerdir. Bu durumu modele yansıtmak amacıyla, Majör ve Minör eksen uzunlukları kullanılarak 3 boyutlu elipsoid hacim veri setine entegre edilmiş ve "Pseudo_Volume" adlı yeni bir sütun oluşturulmuştur.

$$(Volume = \frac{4}{3}\pi r_1 r_2^2)$$

Bu yeni değişkenler sayesinde veri setinin bilgi kapasitesi (information gain) zenginleştirilmiş ve modelin örüntü tanıma kapasitesi artırılmıştır. Özellikle sadece iki boyutlu ölçümlerin yetersiz kaldığı, morfolojik olarak birbirine çok benzeyen türlerin (örneğin Sıra ve Dermason) yüksek boyutlu uzayda ayrıştırılmasında, türetilen bu fiziksel metriklerin SVM modelinin karar sınırlarını (decision boundaries) daha hassas çizmesine olanak sağlaması hedeflenmiştir.

4.2. Özellikler Arası İlişkiler: Korelasyon Analizi ve Isı Haritası (Heatmap)



Şekil 4. 2: Özellikler Arası Pearson Korelasyon Isı Haritası

Veri setindeki bağımsız değişkenlerin birbirleriyle olan doğrusal ilişkilerini ve olası bilgi çakışmalarını (multicollinearity) tespit etmek amacıyla Pearson korelasyon matrisi hesaplanmış ve Isı Haritası (Heatmap) aracılığıyla görselleştirilmiştir. Şekil 4.2 incelendiğinde elde edilen temel istatistiksel bulgular şunlardır:

- **Kusursuz Pozitif Korelasyonlar (Kırmızı Tonlar):** "Area" ile "ConvexArea" arasında (1.00) ve "Compactness" ile "ShapeFactor3" arasında (1.00) kusursuz pozitif korelasyon tespit edilmiştir. Ayrıca projede yeni türetilen "Pseudo_Volume" özelliğinin, beklendiği üzere "Area" ile 0.98 oranında çok güçlü bir doğrusal ilişki içinde olduğu görülmüştür.
- **Güçlü Negatif Korelasyonlar (Mavi Tonlar):** Yine projeye özgü olarak türetilen "Shape_Complexity" (Şekil Karmaşıklığı) metriğinin, "Compactness" ile -1.00 ve "roundness" ile -0.61 oranında ters yönlü (negatif) bir ilişkiye sahip olduğu kanıtlanmıştır. Bu durum, şekil karmaşıklıkla yuvarlaklık formunun bozulduğunu matematiksel olarak doğrulamaktadır.
- **Çoklu Doğrusal Bağlantı (Multicollinearity) Yaklaşımı:** İstatistiksel olarak 1.00 korelasyonlu değişkenlerin ("Area" ve "ConvexArea") modele sunduğu varyans ve bilgi neredeyse tamamen örtüşmektedir. Ancak bu çalışmada, veri setinin orijinal geometrik özellik uzayını (feature space) bozmamak ve türetilen yeni metriklerin ana değişkenlerle olan ilişkisini korumak adına Temel Bileşenler Analizi (PCA) gibi bir boyut indirgeme tekniğine başvurulmamıştır. Tercih edilen SVM algoritması, özellikle RBF (Radial Basis Function) çekirdeğinin yüksek boyutlu uzaydaki esnekliği sayesinde bu tür çoklu bağlantı (multicollinearity) sorunlarını başarıyla tolere edebilmektedir. Dolayısıyla, bu sütunlar modele yeni bir bilgi sağlamasalar da korunmuşlar ve sınıflandırma performansı üzerindeki olası negatif etkileri ihmal edilebilir düzeyde kalmıştır.

4.3. Özellik Ölçeklendirme ve Standardizasyon (SVM Modeli İçin Verinin Hazırlanması)

Veri setinde yer alan bağımsız değişkenlerin ölçekleri ve değer aralıkları birbirinden çok farklıdır. Örneğin, "Area" (Alan) ve "Pseudo_Volume" (Sözde Hacim) değişkenleri yüz binlerle ifade edilen devasa sayılara sahipken, "Eccentricity" veya "ShapeFactor" gibi değişkenler 0 ile 1 aralığında çok küçük ondalıklı değerler almaktadır.

Projede temel sınıflandırma algoritması olarak seçilen Destek Vektör Makineleri (SVM - Support Vector Machines), veri noktaları arasındaki geometrik mesafeleri (örneğin Öklid uzaklığı) hesaplayarak optimum ayırım hiperdüzlemini (hyperplane) bulmaya çalışır. Eğer veriler ölçeklendirilmezse, model büyük sayılara sahip özelliklerin daha "önemli" olduğunu zannedecek ve küçük sayısal değerlere sahip ancak sınıflandırma için kritik olan şekil özelliklerini (Compactness vb.) göz ardı edecektir.

Bu problemi ortadan kaldırmak ve tüm özelliklerin modele eşit ağırlıkta etki etmesini (adilliği) sağlamak amacıyla, veri setindeki tüm bağımsız değişkenlere StandardScaler (Z-skoru standardizasyonu) uygulanmıştır. Bu matematiksel dönüşüm, her bir veri noktasından o sütunun ortalamasının çıkarılıp standart sapmasına bölünmesiyle hesaplanır:

$$z = \frac{x - \mu}{\sigma}$$

Dönüşüm sonucunda elde edilen yeni veri seti incelendiğinde; tüm bağımsız değişkenlerin ortalaması 0 ve standart sapması 1 olacak şekilde standartlaştırıldığı, değerlerin büyük ölçüde -3 ile +3 aralığına homojen bir şekilde dağıldığı doğrulanmıştır. Bu sayede veri seti, SVM algoritmasının yüksek boyutlu uzayda en yüksek doğruluğu (accuracy) ve en hızlı yakınsamayı (convergence) sağlayabileceği optimal formata getirilmiştir.

Not: Veri Sızıntısını (Data Leakage) kesinlikle önlemek amacıyla, standardizasyon (StandardScaler) işlemi tüm veri setine tek seferde uygulanmamıştır. Veri seti Eğitim (Train) ve Test olarak ikiye ayrıldıktan sonra, scaler objesi YALNIZCA Eğitim seti üzerinde eğitilmiş (fit), ardından öğrenilen bu parametreler ile hem Eğitim hem de Test setlerine dönüştürme (transform) işlemi uygulanmıştır.

5. MODELLEME SÜRECİ(MODELING)

5.1. Veri Setinin Bağımsız Özellikler(X) ve Bağımlı Sınıf(y) Olarak Ayrılması

Makine öğrenmesi algoritmalarının denetimli öğrenme (supervised learning) yapabilmesi için veri setinin girdi (input) ve çıktı (output) olarak iki temel bileşene ayrılması gerekmektedir. Bu projede; fasulyelerin fiziksel boyutlarını, şekilsel formlarını belirten 16 orijinal ölçüm ve özellik mühendisliği aşamasında türetilen 2 yeni özellik (Shape_Complexity, Pseudo_Volume) olmak üzere toplam 18 adet sayısal sütun, modelin bağımsız değişkenleri (X matrisi) olarak tanımlanmıştır. Algoritmanın tahmin etmeye çalışacağı, fasulyelerin ait olduğu 7 farklı kategoriye (Dermason, Bombay, Seker vb.) barındıran "Class" sütunu ise bağımlı hedef değişken (Y vektörü) olarak veri setinden izole edilmiştir.

5.2. Veri Bölümleme Stratejisi: Eğitim (Train) ve Test Setleri

Modelin daha önce hiç görmediği veriler üzerindeki genelleme yeteneğini ve gerçek dünya performansını adil bir şekilde ölçebilmek amacıyla, elde edilen bağımsız (X) ve bağımlı (y) değişkenler %80 Eğitim (Train) ve %20 Test seti olacak şekilde rastgele ikiye bölünmüştür.

Bölme işlemi esnasında, veri setindeki sınıf dengesizliğinin model eğitimi olumsuz etkilemesini önlemek amacıyla tabakalı örnekleme (stratified sampling) yöntemi kullanılmıştır (stratify=y). Bu sayede, azınlıkta olan (örneğin Bombay) ve çoğunlukta olan (örneğin Dermason) fasulye türlerinin Eğitim ve Test setlerindeki oransal dağılımının orijinal veri setiyle birebir aynı kalması güvence altına alınmıştır.

Gerçekleştirilen işlem sonucunda modelin eğitimi için 9.314 örnek, test edilmesi için ise 2.329 örnek ayrılmıştır.

(Not: Veri sızıntısını (Data Leakage) önlemek amacıyla bu adımdan hemen sonra uygulanan standardizasyon işlemi, raporun 4.3 bölümünde teorik ve pratik detaylarıyla ele alınmıştır. Hiperparametre optimizasyonu ve model

değerlendirme aşamalarındaki doğrulama (validation) işlemleri ise, ayrılan bu Eğitim seti üzerinde Bölüm 5.3'te detaylandırılacak olan K-Fold Çapraz Doğrulama yöntemi ile gerçekleştirilmiştir.)

5.3. Doğrulama (Validation) Stratejisi: K-Fold Çapraz Doğrulama Entegrasyonu

Makine öğrenmesi modellerinin eğitim verisini ezberlemesini (overfitting) engellemek ve modelin verinin farklı alt kümelerindeki istikrarını (robustness) ölçmek amacıyla, klasik bir "tek seferlik" validasyon ayırımı yerine K-Katlamalı Çapraz Doğrulama (K-Fold Cross Validation) yöntemi tercih edilmiştir.

Bu projede çapraz doğrulama parametresi **K=5** olarak belirlenmiştir. Bu strateji doğrultusunda, 9.314 örnekten oluşan Eğitim (Train) seti kendi içinde rastgele 5 eşit parçaya (fold) bölünmüştür. Model, her bir iterasyonda bu parçalardan 4'ü ile eğitilmiş ve kalan 1 parça ile doğrulanmıştır (validation). Bu işlem 5 kez tekrarlanarak verideki her bir parçanın en az bir kez doğrulama seti olarak kullanılması sağlanmıştır.

Eğitim seti üzerinde gerçekleştirilen 5 iterasyonlu çapraz doğrulama sonucunda elde edilen ortalama validasyon doğruluğu (Validation Accuracy) **%95.19** olarak hesaplanmıştır. İterasyon skorlarının birbirine çok yakın olması (**0.94 - 0.95 aralığı**), modelin veriyi ezberlemediğini ve yüksek genelleme yeteneğine sahip olduğunu kanıtlamaktadır.

5.4. Destek Vektör Makineleri (SVM) Model Mimarisi ve Hiperparametre Seçimi (Kernel Seçimi)

Fasulye türlerinin sınıflandırılması probleminde, veri setindeki özelliklerin (geometrik ve şekilsel ölçümler) doğrusal olarak birbirinden tam anlamıyla ayıramayacak kadar iç içe geçmiş (non-linear) bir yapıda olduğu EDA (Keşifsel Veri Analizi) aşamasında gözlemlenmiştir. Bu karmaşık yapıyı çözebilmek amacıyla SVM modelinin temel mimarisinde hiperparametre optimizasyonuna gidilmiş ve çekirdek fonksiyonu olarak Radyal Tabanlı Fonksiyon (RBF - Radial Basis Function) tercih edilmiştir (kernel='rbf'). RBF Kernel, düşük boyutlu veriyi sonsuz boyutlu bir uzaya taşıyarak doğrusal olmayan (non-linear) karmaşık sınırları çizibilme yeteneğine sahiptir.

Ek olarak, veri setindeki "Bombay" türünün az, "Dermason" türünün ise çok olmasından kaynaklanan sınıf dengesizliğinin modeli çoğunluk sınıfına doğru kaydırmasını (bias) engellemek amacıyla class_weight='balanced' hiperparametresi kullanılmıştır. Ayrıca modelin karar sınırlarının (margin) katılığı ve eğitim verilerinin etki alanı, Scikit-learn kütüphanesinin sunduğu optimum varsayılan hiperparametreler olan C=1.0 ve gamma='scale' değerleri ile yapılandırılarak eğitime sokulmuştur.

Hiperparametreleri belirlenen ve eğitimi tamamlanan SVM modeli, test seti üzerinde sınandığında şu nihai sonuçları vermiştir:

- **Genel Doğruluk (Accuracy): %96.14**
- **Makro Ortalama F1-Skoru: %0.97**


Nihai test doğruluk oranının (%96.14), çapraz doğrulama (CV) ortalamasından (%95.19) kısmen yüksek çıkması istatistiksel olarak beklenen bir durumdur. Bu varyans farklılığı; veri setinin eğitim ve test olarak rastgele bölünmesi sırasında, modelin sıfır hata ile ayırt edebildiği "Bombay" ve "Horoz" gibi morfolojik olarak belirgin örneklerin test setine homojen bir şekilde düşmesinden ve veri sızıntısını önlemek amacıyla uygulanan izole standardizasyon (StandardScaler) işleminin test setindeki bu spesifik dağılıma sağladığı optimizasyon avantajından kaynaklanmaktadır. Modelin sınıf bazlı detaylı performans metrikleri (Hassasiyet, Duyarlılık ve F1-Skorları) **Tablo 5.4'de** sunulmuştur:

Tablo 5.4: SVM Modeli Sınıflandırma Raporu (Classification Report)

Fasulye Türü	Hassasiyet (Precision)	Duyarlılık (Recall)	F1-Skoru	Destek (Support - Örnek Sayısı)
Barbunya	0.98	0.96	0.97	228
Bombay	1.00	1.00	1.00	91
Çalı	0.96	0.98	0.97	288
Dermason	0.96	0.93	0.94	622
Horoz	1.00	0.99	1.00	307
Şeker	0.96	0.99	0.98	330
Sıra	0.92	0.94	0.93	463
Genel Doğruluk	-	-	0.96	2329

6. PERFORMANS DEĞERLENDİRMESİ VE AKADEMİK KARŞILAŞTIRMA

6.1. Sınıflandırma Sonuçları Karmaşıklık Matrisi (Confusion Matrix) Görselleştirmesi



Şekil 6.1: SVM Modeli Sınıflandırma Karmaşıklık Matrisi

Şekil 6.1'de sunulan karmaşıklık matrisi (confusion matrix) incelendiğinde, ana köşegen (diagonal) üzerinde yoğunlaşan koyu renkli yüksek değerler, modelin sınıflandırma performansının genel başarısını görsel olarak doğrulamaktadır. Model; "Bombay" türündeki 91 örneğin tamamını doğru tahmin ederek %100 doğruluk sağlamış, benzer şekilde "Horoz" türündeki 307 örneğin 305'ini eksiksiz sınıflandırarak iri boyutlu ve belirgin şekilli türlerde kusursuza yakın bir ayırım gücü sergilemiştir.

Matris üzerindeki hatalı sınıflandırmalar (köşegen dışı değerler) detaylı incelendiğinde, en belirgin karışıklığın Dermason ve Sıra türleri arasında yaşandığı tespit edilmiştir. Model, gerçekte Dermason olan 36 örneği Sıra; gerçekte Sıra olan 21 örneği ise Dermason olarak tahmin etmiştir. Bu durum, söz konusu iki fasulye türünün morfolojik olarak (boyut ve şekil faktörleri açısından) birbirlerine literatürde de belirtildiği üzere oldukça benzer olmasından kaynaklanmaktadır. İkinci en yüksek hata payı ise 9 adet Barbunya örneğinin Çalı olarak tahmin edilmesiyle görülmüştür. Bu istisnai morfolojik kesişimler dışında modelin hata varyansı minimumda kalmış ve SVM algoritmasının yüksek boyutlu uzayda doğru karar sınırlarını (decision boundaries) başarıyla çizebildiği kanıtlanmıştır.

6.2. Yaygın Değerlendirme Ölçütlerinin Analizi (Accuracy, Sensitivity, Precision, F-Measure)

Makine öğrenmesi modellerinin performansını sadece genel doğruluk (accuracy) üzerinden değerlendirmek, özellikle çok sınıflı ve sınıf dengesizliği barındıran veri setlerinde yanıltıcı sonuçlar doğurabilmektedir. Bu nedenle, kurulan SVM modelinin başarısı; Hassasiyet (Precision), Duyarlılık (Sensitivity/Recall) ve F-Ölçütü (F-Measure) gibi detaylı metrikler üzerinden de analiz edilmiştir.

- **Genel Doğruluk (Accuracy - %96.14):** Modelin tüm test veri setinde doğru tahmin ettiği örneklerin toplam oranıdır. Bu yüksek oran, modelin veri setinin genel yapısını başarıyla öğrendiğini gösterir.
- **Duyarlılık (Sensitivity / Recall):** Modelin, gerçekten o sınıfa ait olan örnekleri ne kadar eksiksiz yakalayabildiğini ölçer. Bombay türünde bu oran 1.00 (tam başarı) iken, en çok karışan Dermason türünde dahi 0.93'ün altına düşmeyerek modelin "gözden kaçırma" (False Negative) hatasının çok düşük olduğunu kanıtlamıştır.
- **Hassasiyet (Precision):** Modelin belirli bir sınıf olarak tahmin ettiği örneklerin yüzde kaçının gerçekten o sınıfa ait olduğunu gösterir. Elde edilen ortalama 0.97'lik makro skor, modelin yanlış alarm (False Positive) verme oranının minimumda kaldığını ve tahminlerinin son derece isabetli olduğunu doğrular.
- **F-Ölçütü (F-Measure / F1-Score - Ortalama 0.97):** Hassasiyet ve Duyarlılık metriklerinin harmonik ortalamasıdır. Sınıf dengesizliği olan veri setlerinde en güvenilir metriktir. Makro ortalamada 0.97'ye ulaşılması, hiperparametre optimizasyonunda kullandığımız sınıf dengeleme (class_weight='balanced') stratejisinin kusursuz çalıştığını ispatlar.

6.3. Elde Edilen Deneysel Sonuçların Referans Akademik Makale ile Kıyaslanması

Bu projede elde edilen model performans metrikleri, temel alınan "**Multiclass Classification of Dry Beans Using Computer Vision and Machine Learning Techniques**" (Koklu ve Ozkan, 2020) başlıklı referans makalenin sonuçları ile doğrudan karşılaştırılmıştır.

Tablo 6.3: Referans Makale ve Proje Sonuçlarının Karşılaştırılması

Çalışma / Model Mimarisi	Genel Doğruluk (Accuracy)	İyileştirme Stratejisi
Koklu ve Ozkan (2020) - Temel SVM Modeli	%93.13	Ham veri, standart modelleme
Geliştirilen Proje - Optimize Edilmiş SVM	%96.14	Kapsamlı EDA ve Özellik Mühendisliği

Referans çalışmaya kıyasla elde edilen bu belirgin performans artışının (skor sıçramasının) arkasında yatan üç temel analitik neden şunlardır:

1. **Aykırı Değer (Outlier) Yönetimi:** Orijinal verideki aşırı uç değerler IQR (Interquartile Range) yöntemi ile temizlenmiş, böylece modelin karar sınırlarını bozan veri gürültüsü (noise) ortadan kaldırılmıştır.
2. **Özellik Mühendisliği (Feature Engineering):** Orijinal ölçümlere ek olarak türetilen "Shape_Complexity" ve "Pseudo_Volume" (Sözde Hacim) metrikleri, modele ekstra ayırt edici geometrik bilgiler sunarak özellik uzayını zenginleştirmiştir.
3. **Hiperparametre ve Sınıf Optimizasyonu:** class_weight='balanced' parametresi ile veri setindeki sınıf dengesizliği matematiksel olarak cezalandırılmış ve azınlık sınıfları (örn. Bombay) güvence altına alınmıştır.

7. SONUÇ VE DEĞERLENDİRME

7.1. Proje Kazanımları ve Bulguların Özeti

Bu çalışmada, tarım sektöründe tohum sınıflandırma süreçlerini otomatize etmek ve verimliliği artırmak amacıyla, yedi farklı kuru fasulye türüne ait geometrik ve morfolojik veriler kullanılarak makine öğrenmesi tabanlı bir sınıflandırma sistemi geliştirilmiştir. Proje kapsamında verinin ham halinden başlanarak kapsamlı bir Keşifsel Veri Analizi (EDA) yürütülmüş, veri setindeki aykırı değerler istatistiksel yöntemlerle (IQR) temizlenmiş ve modelin öğrenme kapasitesini artırmak için özellik mühendisliği (Feature Engineering) teknikleriyle yeni metrikler türetilmiştir.

Geliştirilen Destek Vektör Makineleri (SVM) modeli, elde edilen bulgulara göre **%96.14** gibi oldukça yüksek bir genel doğruluk (accuracy) oranına ulaşmıştır. Modelin sınıflandırma performansına dair bulgular detaylı incelendiğinde; veri setindeki en büyük boyutlu tür olan "Bombay" ve belirgin yapıdaki "Horoz" türlerinin sıfır hata payıyla (%100 F1-Skoru) sınıflandırılabilirdiği görülmüştür. Öte yandan, morfolojik ölçümleri birbirine son derece yakın olan "Dermason" ve "Sıra" türleri arasında beklenen ve kabul edilebilir düzeyde kısmi bir karışıklık yaşandığı tespit edilmiştir.

Buna rağmen, hiperparametre optimizasyonu ve sınıf dengeleme stratejileri sayesinde en düşük sınıf başarı oranı bile %93'ün üzerinde tutulmuştur. Elde edilen nihai %96.14'lük doğruluk oranı, temel alınan Koklu ve Ozkan (2020) makalesindeki %93.13'lük başarı barajını **%3.01** oranında aşarak, uygulanan veri ön işleme ve özellik optimizasyonu adımlarının bilimsel geçerliliğini ve üstünlüğünü kanıtlamıştır. Sonuç olarak bu proje, sadece mevcut bir makaleyi yeniden üretmekle kalmamış, aynı zamanda veriye doğru istatistiksel yaklaşımlarla müdahale edildiğinde makine öğrenmesi algoritmalarının potansiyelinin ne kadar artırılabilceğini somut bir şekilde ortaya koymuştur.

KAYNAKÇA

Koklu, M., & Ozkan, I. A. (2020). Multiclass classification of dry beans using computer vision and machine learning techniques. *Computers and Electronics in Agriculture*, 174, 105507.